

序列对比//目的:根据功能或演化关系,有序检测间相似性//**各种符号**:-|完全一致,:性质相近,~不相近,-gap//**评分机制**: $\Sigma score - gap$ 的惩罚//**全局比对和动态规划**//**枚举法**:枚举所有情况, C_n^m 个//**全局比对**:最好=前最好+这最好//**动态规划**:pic//公式//**局部比对**:忽略:重要性(重要位点,保守):比对内含子无意义,优化//**局部比对更能反映生物学关系**:全局开销大,不匹配位置可能成为对比的瓶颈//**BLAST**:大型数据库中比对耗时,匹配的基因只会出现在主对角线附近//**马尔可夫模型**//**马尔科夫链**:模拟伪随机变化系统的统计模型,描述状态转移过程,未来仅取决于当前//**组成**:状态转移概率矩阵,初始概率分布;当前状态 // **在序列对比中的作用**:状态:配对 M;X,X insert;Y//pic//**HMM**:状态路径无法观测,从可观测的参数中推断;多了生成概率矩阵//**三大问题**:评估:给定条件,计算观测序列出现的概率;学习模型:已知序列估计模型参数,使得模型观测序列出现的概率最大;解码/预测问题:在给定观测序列和模型下,求最可能的隐状态序列//**预测模型**:对数概率相加//**多序列对比**//**用途**:进化分析:鉴定物种同源性;功能分析:鉴定保守区域和家族;结构分析:识别序列的共同变化,同源性建模;鉴定保守的引物结合位点//**方法**:比对和:两两比对,累和所有分数;渐进式:用于已归类的子组之间的对比,组间顺序不可变,GAP 只能加不能减;Clustal:采用全局序列比对法进行所有序列的两两比对,构建距离矩阵(即差异性矩阵),矩阵用于聚类算法的分析//**DNA 还是蛋白质**?:蛋白质更具说服力;DNA 很难匹配时,将其翻译//**基因测序**//**组学**:是研究生物系统中各类分子整体集合的学科,以-omics 结尾,基因组学、转录组学、蛋白质组学、代谢组学(糖组学、脂类组学)//**三代测序的差别**:一代:桑格测序,成本低,精度高,速度慢,效率低,用于法医鉴定和基因检测等;二代:高通量测序平台,速度快,效率高,精度不高,能测长片段,用于肿瘤基因检测;三代:单分子测序计数,全基因检测,精度低//**Illumina 测序步骤**:建库:DNA 文库指两头接上了特点接头的 DNA 片段;桥式 PCR:把 DNA 文库中知道 flowcell 上,进行 PCR 扩增;读取 reads:一次循环只能延长一个碱基,之后用水洗脱多余的聚合酶和 dNTP,然后激光扫描,根据荧光标记判断碱基//**基因突变**//**变异来源**:遗传自父母;新发突变;体细胞突变//**分类与命名**:突变 Mutation,<1%,多态性 polymorphism 性状不同,可能>5%,变异 variation 很常见,变异体 variant //**同义非同义**:氨基酸是否改变//**SPNs**:单核苷酸多态性,很常见;**indels**:一/多个碱基对的插入和删除//**常见的基因组变异类型**:染色体数目异常,结构异常;SNPs;indel//**基因突变检测流程**:建库与测序(DNA 样本和扩展);质控与数据清洗(FASTQ 文件,分数 Phred Score);序列比对,读数映射(SAM/BAM 文件);变异识别(VCF 文件);有害突变筛选与注释(功能/致病性评估)//**Phred 质量分数**: $Q = -10 \lg p$, $Q < 20$ 认为不可靠,当其比例达到 20%这条序列可丢弃//每部分的含义 pic//**VCF 文件**:突变分析的核心输入,记录 SNP/indel 等,后续的 GWAS、PCA 和结构分析都依赖它//**变异!=疾病**:需要结合遗传模型、保守性、疾病相关性判断其临床意义//**基因-表型关系的复杂性**:同一突变在不同个体中可能导致不同后果//**读数深度**:覆盖不足可能假阳性;但若质量高,也可能预警潜在突变//**高频变异未必致病**:低频

变异也未必无害//**单个 read 不成为证据**:但若处于关键区域/高度保守区域可能有大影响//**GWAS**//**GWAS**:用全基因组 SNP 阵列扫描大量个体,找出与特定表现相关的遗传变异;重点在于比较病例组与对照组中 SNP 等位基因的频率差异//**数据处理与分析流程**//数据准备与整合//根据数据特点选择统计检验:频数低,采用 Fisher's exact test;频数大,可用卡方检验,需考虑近似算法可能不准确,可采用蒙特卡洛//多重测试校正,当数据水平为百万个 SNP 时, $p < 5e-8$ (Bonferroni 矫正),但是可能导致真阳性被错过,可以用 FDR 等替代//**结果可视化与解读**//曼哈顿图:将每个 SNP 的 $-\lg(p)$ 值在图上展示,结合生物学意义进一步筛选候选区域//结果解读:结合基因的功能注释和已有文献,确定其可能的致病机制//**孟德尔随机化**//从 **GWAS 而来**:仅 p 值无法确定基因的影响大小,不可解释//**风险评估**:绝对,相对,OR//**孟德尔随机化**:明确暴露和结果的因果关系;三大假设:关联性,独立性,排他性;根据孟德尔分离&自由组合,SNP 是工具变量;优势:基因随机分配;不需要大样本 RCT(伦理,开销,混杂因素多/难控制);越来越多的 GWAS 可以直接用//**结果解读**:往往是 OR 的值,CI 和 p 值;Cochran's Q:表示质异性, p 值显著是质异;MR-Egger 应对方向性多效性(混杂因素),看截距(不显著非 0)//**可视化解读**:森林图:是 CI,看总体和每个的分布,质异性分析//散点图:X:SNP 对暴露的效应,Y:对结局的效应;效应指的是回归系数//漏斗图:对称,否则考虑质异性;点都在底部,存在发布偏见或系统误差;离群值//**突变功能注释**//**功能注释**:区分有害/中性:氨基酸的替换分数,正中性,负有害//**主流工具和流程**//**打分标准**:SIFT, $p < .05$;PloypPhen2:0-1,1 有害;CADD:前 1%有害=20;ANNOVAR:筛选和汇总//**SIFT 与 PolyPhen2 结果矛盾**:在不同物种,不同蛋白区域的效果不一,前提假设不同,按需要来选择//**使用注释工具只用于判定**:不等于致病性证据,需要结合 ACMG 指南和多数据库交叉验证//**CADD 本质区别**:给出在全基因组中的有害程度(标准化阈值);综合多种方法//**Alphamissense**:弱标签,避免标注导致的循环性;结合无监督蛋白质语言建模任务来学习基于序列上下文的氨基酸分布;利用 AlphaFold 衍生系统来融入结构中的上下文信息;利于罕见变异与新结构变异的高效识别//**RNA 测序**//**基因表达**:转录水平的 mRNA 反映基因活跃度//**RNA-seq**:对 mRNA 进行高通量测序;关键步骤:RNA 提取;反转录:逆转录酶(效率与质量会影响文库代表性),cDNA 稳定便于扩增;文库构建:断片化,接头连接,PCR 扩增;高通量测序:illumina 等平台;数据分析//**表达量归一**:为什么:reads 受基因长度,测序深度,转录本丰度影响//**RPKM**:单端;FPKM:双端测序;TPM:总和相同,能体现出某个基因的 reads 比例,直接样本间比//**差异分析**:过滤低表达量的基因,FP;常用软件:DESeq2;负二项;需要重复样本;主流,稳定;edgeR:负二项;需要;适合小样本//**筛选标准**:Fold Change>2,q-value/FDR <.05//**差异不能代表生物机制,需要进一步富集分析等二次注释**//**WGCNA**//**WGCNA**:利用基因间相互作用关系构建网络,进行基因模块研究,识别核心基因的方法;筛选有生物学意义的功能模块和核心调控点;适用于复杂疾病中挖掘微弱效应/协同调控和模块级调控信号//**关键术语**:共表达//邻接矩阵//拓扑重叠矩阵 TOM//模块//模块特征

基因 ME//模块成员度 MM//基因显著性 GS//**具体流程**//数据准备与样本筛选//构建网络 //模块识别与合并//模块与表型相关性//模块内基因分析//**替代 RNA-seq**:不行,前者关注结构和模式,后者关注是否显著//**软/硬阈值**:软的能保留一些微弱的信息//**WGCNA 推因果**:基于相关性的手段,没有因果性//**数据缺失**:清理缺失严重的数据//**功能富集分析**//**GO**:Gene Ontology 基因本体论;从生物学过程,细胞组分,分子功能三方面对基因及产物进行注释;统计注释到相应 GO term 上的基因数目和其中的差异基因数目//**KEGG**:利用图像展示代谢途径和各种途径的关系;直观反映基因表达差异对代谢通路的影响;将差异基因在通路上标注;全面了解代谢途径//**数据挖掘过程** // **P 值修正**:Family Wise;FDR//**Metascape**:一站式功能富集工具;ID 转换;注释;归类,获取感兴趣的基因集(存在多个,产生多个富集通路);富集//**分析结果图**:横坐标 $-\lg(p)$,越小的 p 在越上面,富集越显著;纵向是不同的富集通路(基因)//**后续做什么**?:已经发现了关键基因后:挖掘上/下游基因;找到转录因子