

Lecture 3 要点回顾

一、要点回顾

1. 核心概念与理论基础

- 1) **GWAS 定义与目的**
 - a) 利用全基因组 SNP 阵列扫描大量个体，找出与特定表型（如疾病）相关的遗传变异。
 - b) 重点在于比较病例组与对照组中各 SNP 等位基因的频率差异。
- 2) **假设检验框架**
 - a) **零假设 (H_0):** 指定基因型与表型无关联。
 - b) **备择假设 (H_a):** 存在统计学上显著的基因型与表型关联。
 - c) 检验过程包括选择合适的统计模型、计算 p 值、设定拒绝域（例如 $p < 0.05$ ）并根据结果判断是否拒绝零假设。

2. 数据处理与分析流程

- 1) **数据准备与整合**
 - a) 基因型数据和表型数据均为长格式（样本编码、SNP/表型名称、取值）。
 - b) 关键：使用 R 语言中的 tidyr 包 (pivot_wider) 将数据从长格式转换为宽格式，确保样本信息对齐，便于后续统计检验。
- 2) **构建列联表与统计检验**
 - a) 利用 R 的 xtabs 函数构建每个 SNP 与对应表型的频数列联表。
 - b) 根据数据特点选择统计检验：
 - ① 当频数较低时，采用 Fisher's exact test。
 - ② 若频数较大，可用卡方检验，但需考虑近似算法可能不准确，可采用 Monte Carlo 模拟 (simulate.p.value=TRUE)。
- 3) **多重测试校正**
 - a) 因为 GWAS 同时测试上百万个 SNP，单一 $p < 0.05$ 的标准会产生大量假阳性。
 - b) 采用 Bonferroni 校正方法，将全基因组显著性水平设为 $p < 5 \times 10^{-8}$ ，以严格控制假发现率。

3. 结果可视化与解读

- 1) **曼哈顿图**
 - a) 使用 qqman 包绘制曼哈顿图，将每个 SNP 的 $-\log_{10}(p)$ 值在图上展示。
 - b) 高耸“摩天大楼”区域提示可能与表型相关的 SNP，结合生物学意义进一步筛选候选区域。
 - c) 图中标出 Bonferroni 校正后的阈值线，直观显示哪些 SNP 达到全基因组显著水平。
- 2) **结果解读**
 - a) 关注 p 值分布：注意异常低的 p 值区域需要生物学验证；
 - b) 解读过程中结合候选 SNP 所在基因的功能注释和已有文献，确定其可能的致病机制。

4. Lecture3 课后学习的注意事项

- 1) **GWAS 原理和代码**

- a) 理解 GWAS 的统计原理（假设检验、多重测试校正）以及数据预处理在整个流程中的重要作用。
- b) 复习 R 代码时，着重掌握如何构建公式、批量生成列联表以及调用不同检验方法的场景。
- 2) **多重测试校正**
 - a) 特别注意 Bonferroni 校正的意义及其局限：严格控制假阳性，但可能导致部分真阳性被错过；可关注 FDR 等替代方法。
- 3) **图解读及拓展**
 - a) 掌握曼哈顿图的基本构造，理解每个“塔楼”代表的含义，学会从图中初步筛选候选区域，并结合生物学背景进行后续分析。
- 4) **数据细节**
 - a) 数据整合过程中务必检查样本编码、SNP 名称和表型信息的对齐情况；统计检验前后要验证数据是否完整无误。

5. R 语言代码实践要点

- 1) **数据读取与预处理**
 - a) 使用 openxlsx 包读取 xlsx 格式数据，确保基因型与表型数据格式一致。
 - b) 关键在于列名称的统一与正确合并，避免数据对不齐导致统计偏差。
- 2) **数据整形**
 - a) 利用 tidyr::pivot_wider 函数实现长格式到宽格式的转换，使样本编码为行，SNP/表型名称为列。
- 3) **统计检验与循环操作**
 - a) 通过循环对所有 SNP 与各表型构建列联表，并使用 fisher.test 计算每个组合的 p 值。
 - b) 将结果存入矩阵或数据框中，为后续筛选及曼哈顿图绘制做准备。
- 4) **绘制曼哈顿图**
 - a) 构造数据框 gwasMatrix，包含 SNP 名称、染色体信息、位点位置和 p 值。
 - b) 调用 manhattan 函数时设定合适的阈值（annotatePval 和 genomewideline 参数），确保图中能正确标示显著结果。

二、前沿知识拓展与最新进展

- 1. **多组学数据整合与功能注释**
 - 1) **多组学整合：** 当前研究中越来越多地将 GWAS 结果与转录组、表观遗传、蛋白质组、代谢组等数据结合，帮助鉴定功能性变异。例如，通过整合 eQTL（表达数量性状位点）数据，可以实现“转录调控 GWAS”，深入揭示变异对基因表达的影响。
 - 2) **功能注释工具：** 如 CADD、RegulomeDB 和 FunSeq2 等工具，能帮助筛选出可能具有生物学功能的候选变异，并与公共数据库（如 GTEx、ENCODE）中的信息进行比对。
- 2. **精细映射与因果推断**
 - 1) **贝叶斯 GWAS：** 近年来贝叶斯方法被引入 GWAS 分析中，通过建立贝叶斯模型，更直观地量化候选变异的后验概率，有助于细化信号并提高对因果变异的辨识度。
 - 2) **Mendelian Randomization：** 结合 GWAS 结果与流行病学数据，通过孟德

尔随机化来评估候选基因型与疾病之间的因果关系，推动精准医学的发展。

3. 大规模生物库与机器学习方法

- 1) **大型生物库数据：**如 UK Biobank、All of Us 计划等大规模队列为 GWAS 提供了丰富的数据资源，大大提高了统计效能和结果的稳定性。
- 2) **机器学习和深度学习：**近年来，通过引入机器学习方法（如随机森林、XGBoost）和深度学习技术（如卷积神经网络、图神经网络）来挖掘 GWAS 数据，帮助预测多基因风险评分 (PRS)，并改进对复杂疾病遗传背景的解析。

4. 单细胞与空间转录组学的探索

- 1) 单细胞基因组学和空间转录组学技术的兴起，为 GWAS 后续的功能验证和分子机制研究提供了全新的视角。通过在单细胞层面上验证候选基因的表达模式，可以更精确地揭示特定细胞类型中的致病机制。

5. 跨种族和跨群体分析

- 1) 新一代研究越来越注重不同种族和人群间的比较分析，通过跨种族 GWAS，有助于发现普遍适用的致病变异，同时识别特定人群的独特风险因素，推动公平的精准医疗。