

Lecture 5 要点回顾

主题：突变功能注释工具与前沿进展

一、课程核心内容与理论基础

1. 突变功能注释的科学问题

- 如何区分有害 (deleterious) 与中性 (neutral) 突变？
- 突变是否影响蛋白功能？是否与疾病发生有关？

2. 主流功能预测工具介绍与对比

工具	方法原理	输入信息	优势	局限
SIFT	基于跨物种保守性	序列信息	结构简单, 适用于氨基酸替换	覆盖率低, 假阴性高 (31%)
PolyPhen2	结构 + 序列规则 + 贝叶斯分类	蛋白 3D 结构、MSA 等	结构信息丰富时效果更好	结构依赖性强, 经验规则
CADD	支持向量机整合多工具注释	多维功能注释数据	整合性强、全基因组评估、准确率高	黑箱性强, 结果解释难度大
ANNOVAR	综合注释平台	VCF + 数据库	支持多个数据库, 批量分析	不提供致病性评分

二、实操步骤与工具用法概览

1. SIFT 注释流程

- PSI-BLAST 找出同源序列 → 多序列比对 → 评估每个突变位点的保守性
- 分数解释: <0.05 为 damaging, ≥ 0.05 为 tolerated

2. PolyPhen2 注释流程

- 多序列比对 + 蛋白结构建模 → 提取结构特征 → 应用规则或贝叶斯预测
- 分数解释: 值越接近 1, 越可能是有害突变

3. CADD 的创新

- 融合 60 多种注释数据
- 利用真实变异 vs 模拟突变训练 SVM 模型
- 分数解释: $CADD \geq 20$ 表示可能属于前 1%最有害突变

4. ANNOVAR 的使用场景

- 适合 VCF 注释、数据库比对 (基因功能区、频率库、疾病库等)
- 无评分系统, 适合作为筛选和汇总工具

三、课堂演练与思考题

1. 如何通过工具得分判断突变致病性？
2. 当 SIFT 和 PolyPhen2 结果矛盾时, 如何判断？
3. CADD 的评分机制与传统方法有何本质区别？
4. 是否可以用注释工具直接用于临床判定？为何需要结合数据库和生物学背景？

四、注意事项与常见误区

- SIFT 和 PolyPhen2 在不同物种、不同蛋白区域的效果不一, 应理解其假设前提
- 不同工具的数值尺度不一致, 不能直接横向比较

- 工具预测不等于“致病性证据”，应结合 ACMG 指南、多数据库交叉验证
- 数据输入必须为标准格式，尤其是 ANNOVAR 和 VEP 对输入格式要求严格

五、课后拓展与前沿进展

1. 最新工具 AlphaMissense (2023 DeepMind 发布)

- 基于 AlphaFold 衍生结构建模，结合蛋白语言模型
- 使用弱标记数据，突破人工标签循环性
- 利于罕见变异与新结构域变异的高效识别

2. 多组学注释整合趋势

- 结合转录组 (eQTL)、甲基化 (meQTL)、染色质可及性 (ATAC-seq) 等多维数据
- 实现个体化致病机制分析与精准筛查

3. 深度学习在功能预测中的应用

- 图神经网络 (GNN) 用于结构建模与功能识别
- 自监督学习与迁移学习提高小样本预测能力

4. 临床标准与指南

- 了解 ACMG (American College of Medical Genetics) 关于突变注释和致病性分级的最新标准
- 学会将预测工具结果纳入 ACMG 五级分类体系中辅助判读