

Lecture 3.1 RNA 测序原理、表达量计算与差异分析

一、核心概念与理论基础

1. 什么是基因表达？

- 1) 基因表达是指 **DNA 信息被转录成 mRNA，并进一步翻译为蛋白质**的过程。
- 2) DNA → mRNA → 蛋白，转录水平的 mRNA 反映基因活跃程度
- 3) 通常我们用 **mRNA 的丰度**（不是蛋白）来反映基因的表达活性

2. RNA-seq 的基本原理

- 1) RNA-seq（RNA 测序）是对**转录产物进行高通量测序**，用于分析细胞在某一状态下的基因表达谱
- 2) **关键步骤**:

流程	内容说明
RNA 提取	从组织/细胞提取总 RNA
反转录（关键步骤）	使用逆转录酶将 mRNA 逆转录为 cDNA（稳定、便于扩增）
文库构建	断片化、接头连接、PCR 扩增等
高通量测序	Illumina 等平台
数据分析	比对 → 计数 → 表达量标准化 → 差异分析

注：反转录是 RNA-seq 的核心步骤之一。DNA 不能直接读取 mRNA 序列，必须先通过反转录合成 cDNA，再进行后续测序和分析。

二、表达量计算与标准化

1. 为何需要标准化？

- 1) 原始 read 数受以下因素影响：
 - a. 基因长度
 - b. 测序深度
 - c. 转录本丰度

2. 三种常用标准化指标

指标	适用情况	特点
RPKM	单端测序	Reads per Kilobase of transcript per Million mapped reads
FPKM	双端测序	Fragments per Kilobase...
TPM	样本间比较	Transcripts per Million，更适合跨样本比较，总量归一化

注：TPM 保证每个样本的表达总量一致，可用于可视化与样本间比较

三、差异表达分析流程

1. 分析目的

- 1) 判断不同处理/组织/时间条件下**哪些基因被上调或下调**
- 2) 找到潜在疾病标志物、治疗靶点或功能通路

2. 常用分析软件

软件	分布假设	是否需重复样本	特点
DESeq2	负二项	是	最主流，稳定性高
edgeR	负二项	是	适合小样本

3. 筛选标准

- 1) **Fold Change > 2**
- 2) **q-value < 0.05**（多重检验校正，FDR 控制）

四、学习注意事项与常见误区

1. 忽视反转录过程：反转录酶的效率与质量影响文库代表性
2. 直接使用原始 read 数进行比较：需先标准化 (TPM 更可靠)
3. 表达量高 $\neq$ 差异显著：需结合统计检验判断
4. RPKM 用于样本间比较：不可取，应使用 TPM (可用于跨样本比较，表达总量固定，更稳定)
5. 仅用 Fold Change 可以表示表达差异：不够，必须结合统计显著性 (p/q 值) 判断
6. 差异分析=生物机制：差异分析 $\neq$ 生物机制，需结合 GO/KEGG、蛋白互作、文献支持等二次注释

五、前沿知识拓展与下一步学习

1. 多维表达建模思路

- 从单基因出发 $\rightarrow$ 模块表达 $\rightarrow$ 共表达网络 (见下次课 WGCNA)
- 趋势聚类 vs 网络构建 vs 关键驱动因子识别

2. 与其它组学的整合分析

- 转录组 vs 蛋白组/代谢组：分析层级联动
- 与突变 (如 eQTL) 结合：解释遗传调控效应

3. AI 方法在表达数据挖掘中的应用

- 使用**自编码器、图神经网络 (GNN) **等手段进行表达特征提取、疾病预测
- 单细胞 RNA-seq 成为趋势：细胞异质性研究新窗口