

Lecture 3.2 WGCNA 要点回顾

一、核心原理与建模思想

1. WGCNA 定义

Weighted Gene Co-expression Network Analysis, 一种从转录组数据中挖掘模块、构建网络、识别核心基因的系统遗传分析方法。

2. 方法哲学

从“列出显著基因”到“理解网络结构”，强调模块（功能单元）而非个体基因；目标是筛选具生物学意义的**功能模块与核心调控节点**。

3. 适用背景

适用于复杂疾病（如神经精神疾病、代谢病、肿瘤）中，挖掘微弱效应、协同调控和模块级调控信号。

二、关键术语与基本网络概念

概念	解释
共表达 (co-expression)	指两个基因在不同样本中的表达变化趋势高度一致 (相关性高)
邻接矩阵 (adjacency matrix)	表达相关系数 (如 PCC) 转换为“网络边权重”的数值矩阵
TOM 矩阵 (拓扑重叠矩阵)	结合“直接边”+“共同邻居”构建的结构相似性矩阵，增强网络鲁棒性
模块 (module)	网络中一组表达趋势相似、连接紧密的基因子集
模块特征基因 (ME)	模块中所有基因表达主成分 (PC1)，代表模块总体表达模式
模块成员度 (MM)	某基因与模块特征基因的相关性，用于识别“模块代表性强”的基因
基因显著性 (GS)	某基因与外部表型变量的相关性程度，用于寻找与性状强相关的基因

三、分析流程与 R 语言实践步骤

Step 0: 数据准备与样本筛查

- 1) 输入要求：标准化表达矩阵 (基因 × 样本)
- 2) 预处理操作：
 - a) 剔除缺失值较多的基因
 - b) 样本聚类 (hclust) 找出 outlier，手动剪枝确定 cut height

Step 1: 构建网络

子步骤	说明
相似度矩阵	计算基因间 Pearson 相关系数
邻接矩阵	使用 soft-threshold β 幂指数进行变换，保留弱相关性信息 (权重网络)
无尺度网络验证	pickSoftThreshold() 选择合适 β 值，使网络符合 scale-free 性质

Step 2: 模块识别

子步骤	说明
构建 TOM 矩阵	强调结构相似性，缓解噪声影响
计算 dissTOM	使用 $1 - \text{TOM}$ 作为距离矩阵用于聚类
模块识别	动态剪枝树 (Dynamic Tree Cut) 划分模块
合并模块	ME 间相关性 > 0.75 的模块合并，减少冗余

Step 3: 模块与表型相关性分析

- 1) 计算模块特征基因 (ME)
- 2) 计算 ME 与临床性状 (或分组标签) 的相关性热图
- 3) 筛选与性状相关的模块，作为候选“目标模块”

Step 4: 模块内基因分析与 Hub 基因识别

内容	方法
GS-MM 联合图	GS: gene-trait correlation; MM: gene-module correlation
Hub 基因筛选标准	高 GS + 高 MM，或连接度 (k) 最高的前 10%
网络可视化	导出 TOM + 目标模块子图，使用 Cytoscape 绘图

四、学习注意事项与误区纠正

常见问题	正确做法
WGCNA 可以直接替代差异表达分析?	不能。差异分析关注“是否显著”，WGCNA 关注“结构与模式”，二者互补
所有模块都有生物学意义?	不是。需进一步通过 GO/KEGG 富集验证模块功能，过滤无意义模块
邻接矩阵用硬阈值还是软阈值?	推荐 soft thresholding (WGCNA 默认方式)，保留网络信息更完整
可以用 WGCNA 推因果?	不能。WGCNA 是基于相关性，不能判断调控方向性。需联合其他数据 (如 ChIP、eQTL) 分析
数据缺失怎么办?	使用 <code>goodSamplesGenes()</code> 自动清理缺失值严重的数据项

五、前沿拓展与实际应用场景

1. 生物学验证路径

- 1) 模块富集分析 (GO/KEGG): 验证模块功能是否聚焦在某通路或生物过程上
- 2) Cytoscape 可视化: 构建 hub 基因主导的调控网络，探索上游调控路径
- 3) 与突变位点 (eQTL)、蛋白互作数据 (PPI) 整合，提高功能推断可信度

2. 应用实例

- 1) **精神疾病研究**: 识别发病相关模块 (如突触功能、炎症) 并分析轨迹动态
- 2) **癌症多组学**: 构建表达-PPI-突变整合网络，发现驱动模块与耐药机制
- 3) **发育/时序分析**: 基于 WGCNA 识别阶段特异模块与调控因子 (TF)