

Unit 5 Homework

1 相关系数

t16

由于 $z_r = \frac{1}{2} \ln \frac{1+r}{1-r} \sim N(\frac{1}{2} \ln(\frac{1+r_0}{1-r_0}), \frac{1}{n-3})$

$$H_0 : r_0 = 0; H_1 : r_0 \neq 0$$

$$P(z \geq (z_r - \frac{1}{2} \ln \frac{1+r_0}{1-r_0}) \sqrt{n-3}) \leq 0.025$$
$$\therefore n \geq (\frac{2z_{0.025}}{\ln(1+r) - \ln(1-r)})^2 + 3$$

```
In [93]: import scipy.stats as stats
import numpy as np

print("z_0.025=", stats.norm.isf(0.025))
```

z_0.025= 1.9599639845400545

a. $r=0.30, n \geq 43.1, n=44$

b. $r=0.25, n \geq 61.9, n=62$

c. $r=0.20, n \geq 96.5, n=97$

当然这是与 $r=0$ 进行NHST，无法说明总体的线性强度

实际上我也试过对 $r \leq 0.5$ 进行检验，但是最后的结果确是 r 越大得到的 n 越大，这显然是不正确的，原因在于题目给出的 $r < 0.5$ ，会产生负号，这将改变不等号方向，导致错误的检验；而正确的那边是恒成立的，无论 n 的取值，这没有意义

如果说使用95%CI的下限与0比较，我认为和上面的方法结果是一致的（因为我一开始就是下限和0.5做比较），下面给出证明

$$z_L = z_r - z_{0.025} \cdot \frac{1}{\sqrt{n-3}}$$
$$\therefore r_L = \frac{e^{2z_L} - 1}{e^{2z_L} + 1} > 0$$
$$\Rightarrow z_L > 0 \Rightarrow n > (\frac{2z_{0.025}}{\ln(1+r) - \ln(1-r)})^2 + 3$$

t19

首先构造数组

```
In [94]: rank = np.linspace(1,11,11)
grade = [1, 3, 1, 1, 3, 3, 6, 9, 6, 6, 9, 11]

stats.spearmanr(rank, grade)
```

Out [94]: SignificanceResult (statistic=0.907222105138509, pvalue=0.00011539867905256112)

样本的 $\rho=0.91$ ，是非常大的，说明样本的rank和grade有很强的正相关性

而 $\rho = 1e^{-4}$ ，说明总体的 ρ 显著不等于0，但无法用 ρ 值说明总体显著相关

还是使用95%CI来说明

$$z_r = \frac{1}{2} \ln \frac{1+\rho}{1-\rho} \text{ 服从正态分布, } z \text{ 的CI为 } z_r \pm z_{\alpha/2} \sqrt{\frac{1+\rho^2/2}{n-3}}$$

$$\therefore \rho_L = \frac{e^{2z_L} - 1}{e^{2z_L} + 1}, \rho_U = \frac{e^{2z_U} - 1}{e^{2z_U} + 1}$$

只要 $\rho_L \geq 0.5$ ，就能在 $\alpha = 0.05$ 的水平上说明总体显著相关

对于本题， $\rho_L = 0.607 > 0.5$

故认为总体显著相关

2 简单线性回归模型

Julie Vu, Chapter 6/ 6.26

(a) R2 and correlation between lunch and helmet

根据相关系数不随量纲变化的性质和一阶线性回归模型的表示，有

$$r(x, y) = \pm r(\hat{y}, y) = \pm \sqrt{R^2} = -0.85$$

(b)slope and intercept

$$\begin{aligned} \text{sploe} &= \frac{n \sum_i x_i y_i - \sum_i x_i \sum_i y_i}{n \sum_i x_i^2 - (\sum_i x_i)^2} = \frac{\text{COV}(x,y)}{D(x)} \\ \text{intercept} &= \bar{y} - \text{sploe} \cdot \bar{x} \\ \therefore r_{x,y} &= \frac{\text{cov}(x,y)}{\sigma_x \cdot \sigma_y} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2 \sum_i (y_i - \bar{y})^2}} \\ \therefore \text{sploe} &= r \cdot \frac{SD(y)}{SD(x)} = -0.54, \text{intercept} = 55.4\% \end{aligned}$$

(c)what can intercept say?

结合一阶线性回归模型来看，截距是当自变量为0时的因变量值
在本题中指的是当 Rate of Receiving a Reduced-Fee Lunch=0时的Rate of Wearing a Helmet
当自变量没有做随机变量中心化时，截距往往是没有意义的，因为实际情况中自变量往往很少会等于0
当做了随机变量中心化，截距代表自变量为均值时的因变量值

(d)what can slope say?

斜率表示对于总体而言，当自变量增加时，因变量的平均增加值，即某样本自变量比另一个样本自变量大1单位，其因变量比另一个的平均大slope
在本题中指的是当不同社区之间，lunch观测值增加时，平均而言helmet减少量

(e)residual

$$r = (y - \hat{y})^2 = (y - b_0 - b_1 x)^2 = 3.844 \times 10^{-3}$$

残差表示预测模型与样本值的偏离程度，为了消除符号干扰所以平方
具体而言，残差越小表示模型和样本值越符合

3 多元线性回归模型

```
In [95]: import pandas as pd
import numpy as np
import scipy.stats as stats
import seaborn as sns
import matplotlib.pyplot as plt
```

```
In [96]: data = pd.read_csv("Datas/Student_Performance.csv")
data.head()
```

Out[96]:

	HoursStudied	PreviousScores	ExtracurricularActivities	SleepHours	SampleQuestionPapersPracticed	PerformanceIndex
0	7	99	Yes	9	1	91
1	4	82	No	4	2	65
2	8	51	Yes	7	2	45
3	5	52	Yes	5	2	36
4	7	75	No	8	5	66

```
In [97]: data.shape
```

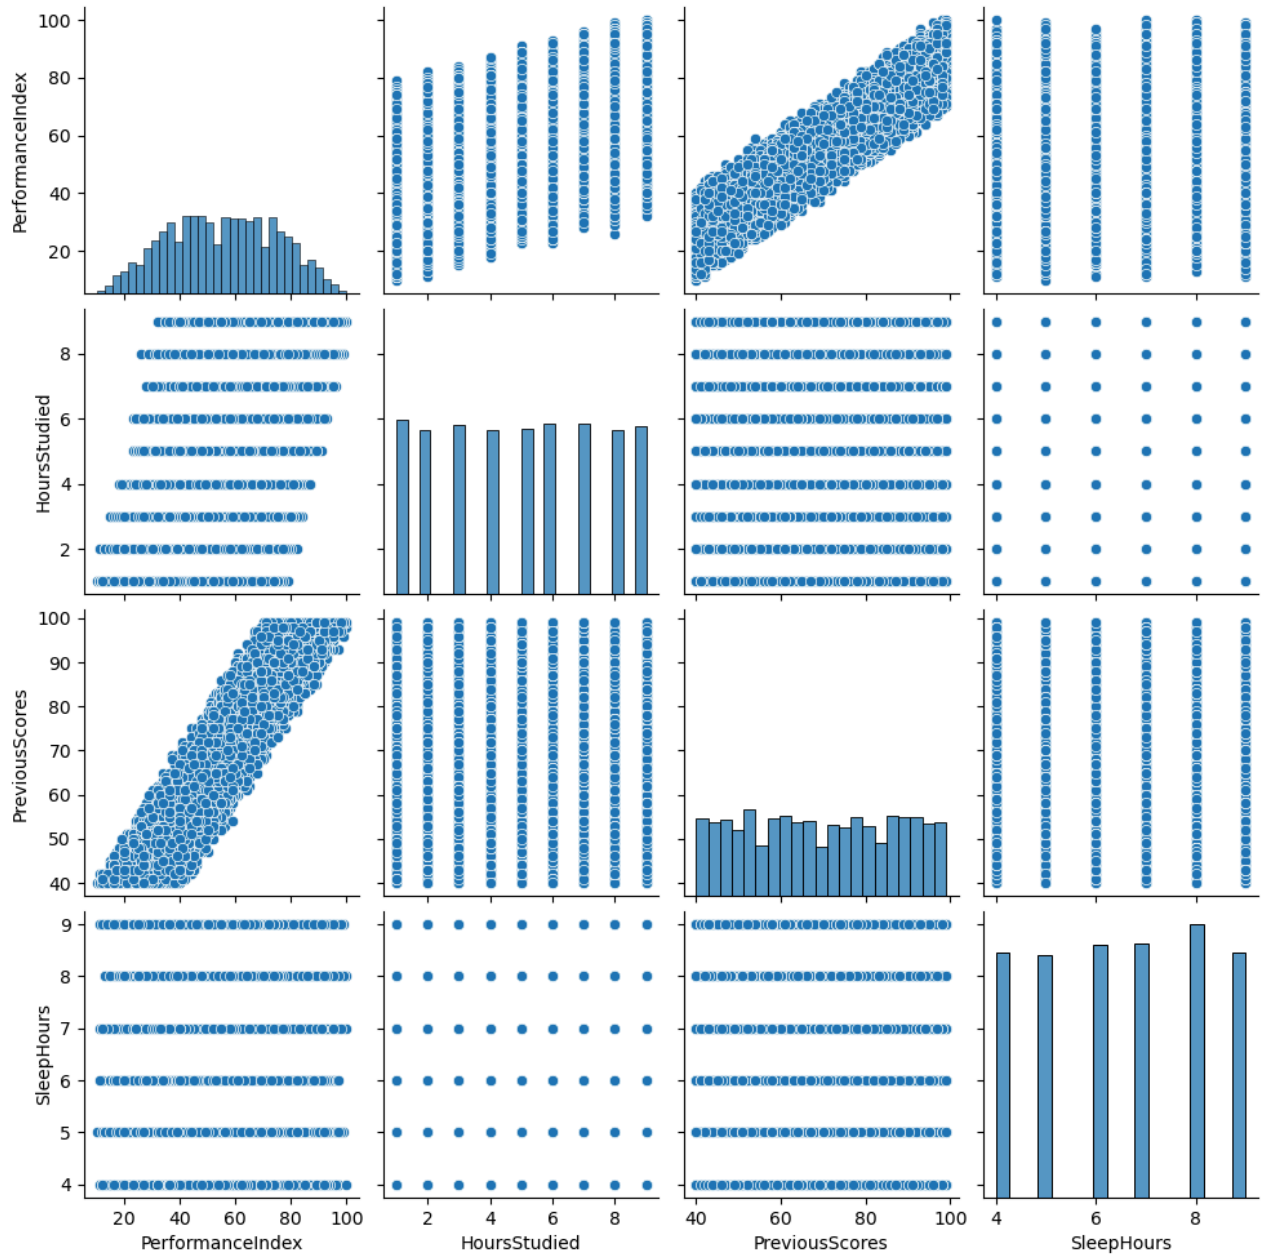
Out[97]: (10000, 6)

3.1 数据可视化

```
In [98]: sns.pairplot(data=data, y_vars=["PerformanceIndex", "HoursStudied", "PreviousScores", "SleepHours"], x_vars=["PerformanceIndex", "HoursStu
```

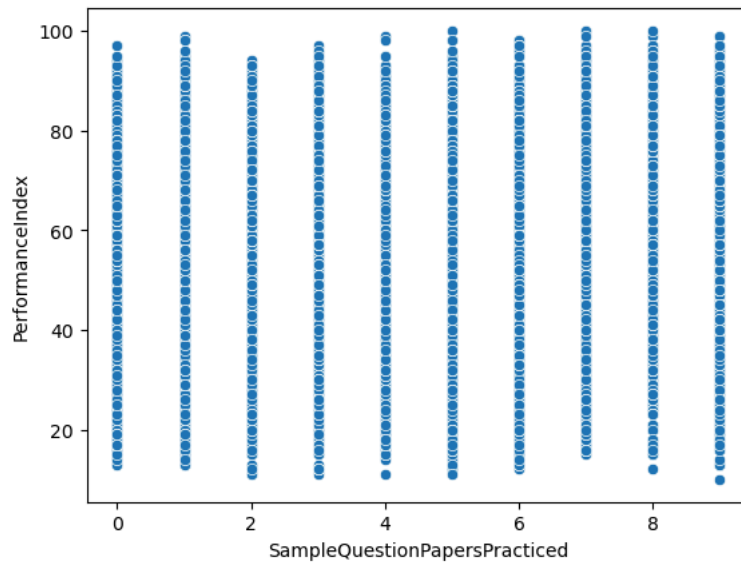
D:\mySoftwares\stem\Anaconda\Lib\site-packages\seaborn\axisgrid.py:118: UserWarning: The figure layout has changed to tight
self._figure.tight_layout(*args, **kwargs)

```
Out[98]: <seaborn.axisgrid.PairGrid at 0x1b6c479f910>
```




```
In [99]: sns.scatterplot(data=data, y="PerformanceIndex", x="SampleQuestionPapersPracticed")
```

```
Out[99]: <Axes: xlabel='SampleQuestionPapersPracticed', ylabel='PerformanceIndex'>
```



```
In [100]: sns.boxplot(data=data, y="PerformanceIndex", x="ExtracurricularActivities")
```

```
Out[100]: <Axes: xlabel='ExtracurricularActivities', ylabel='PerformanceIndex'>
```



3.2 用线性模型尽可能地预测PerformanceIndex

```
In [101]: import statsmodels.formula.api as smf
model = smf.ols("PerformanceIndex~PreviousScores+SleepHours+HoursStudied", data=data)
results = model.fit()
results.summary()
```

```
Out[101]: OLS Regression Results

Dep. Variable: PerformanceIndex    R-squared:    0.988
Model: OLS    Adj. R-squared:    0.988
Method: Least Squares    F-statistic: 2.665e+05
Date: Thu, 30 May 2024    Prob (F-statistic): 0.00
Time: 16:11:05    Log-Likelihood: -21774.
No. Observations: 10000    AIC: 4.356e+04
Df Residuals: 9996    BIC: 4.359e+04
Df Model: 3
Covariance Type: nonrobust

               coef  std err          t  P>|t|  [0.025  0.975]
Intercept -32.9146    0.127  -258.414  0.000  -33.164  -32.665
PreviousScores  1.0188    0.001   827.342  0.000    1.016    1.021
SleepHours  0.4776    0.013   37.928  0.000    0.453    0.502
HoursStudied  2.8572    0.008  346.406  0.000    2.841    2.873

Omnibus: 0.836    Durbin-Watson: 2.002
Prob(Omnibus): 0.658    Jarque-Bera (JB): 0.803
Skew: -0.002    Prob(JB): 0.669
Kurtosis: 3.044    Cond. No. 431.
```

Notes:

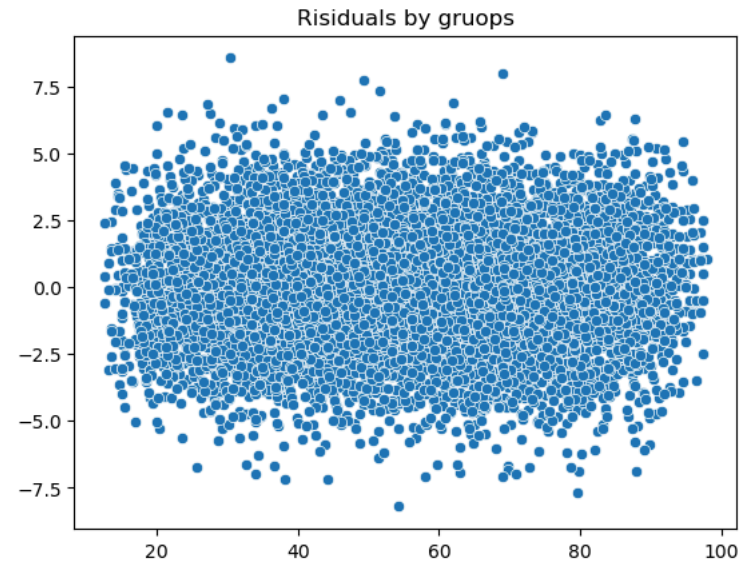
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

经过遍历的尝试，PerformanceIndex~PreviousScores+SleepHours+HoursStudied是最佳的模型

1. R^2_{adj} 和 R^2 此时最大，F-value=1.757E5,非常大，对应的p-value=.00
2. 此时的AIC、BIC和Cond.No.也最小，表明模型兼顾简洁性和精准性，对于预测和拟合（解释）都有效
3. 残差分析见下

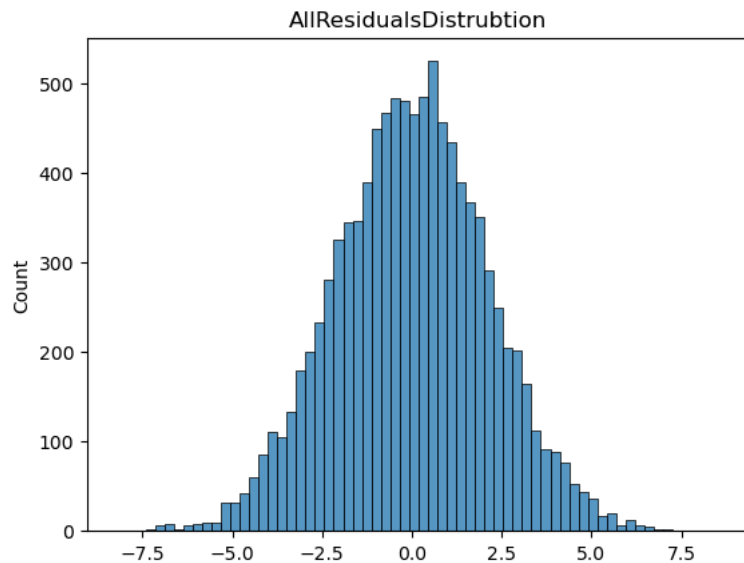
```
In [102]: #残差可视化
residuals = results.resid
fitted_value = results.fittedvalues
sns.scatterplot(x=fitted_value,y=residuals)
plt.title("Risiduals by gruops")
```

```
Out[102]: Text(0.5, 1.0, 'Risiduals by gruops')
```



```
In [103]: sns.histplot(x=residuals)
plt.title("AllResidualsDistrubtion")
```

Out[103]: Text(0.5, 1.0, 'AllResidualsDistrubtion')



做NHST, p 很大, 不能认为显著不正态, 偏度 ≈ 0 , 峰度 ≈ 3 , JB检验也说明了正态性较好
再观察两幅图
综合以上, 可以认为残差的分布非常正态

观察Residuals by groups可以发现, 不同 x 对应的残差分布的方差基本相同
且Durbin-Watson ≈ 2 ,说明残差不存在自相关性, 即方差是基本不变的
故认为残差**方差齐性好**

Cond.No.却非常大, 表明了自变量之间的线性关系很强
这说明模型的**解释性并不好, 但是预测性仍是足够好的**
但是在pairplot上并没有发现其他三个变量有很强的线性关系

报告如下:

PreviousScores($b=1.0, t(9998)=827.34, p=.00$)、SleepHours($b=0.48, t(9998)=39.93, p=.00$)、HoursStudied($b=2.9, t(9998)=346.4, p=.00$)显著地预测了PerformanceIndex, 纵截距($-32.92, t(9998)=-258.4, p=.00$) (可以发现, 当 n 很大时, p 会非常显著, 在统计上), 这些变量也一定程度上解释了成绩 ($R^2=0.988, F(3, 9996)=2.7E05, p=.00$)